

```
from utility.raport_helper_functions import *  
recipe_data = load_recipe_data()
```

Projekt z przedmiotu *Eksploracja Danych*

Etap 1: Zrozumienie problemu i danych

Analizowany zbiór danych: **Brewer's Friend Beer Recipes**

Autorzy:

- Anna Sztukowska 188803
- Michał Sugalski 193290
- Lucjan Gackowski 193150

Ogólny opis zbioru

Zbiór **Brewer's Friend Beer Recipes** zawiera dane dotyczące domowych receptur piwa udostępnianych przez użytkowników platformy Brewer's Friend – narzędzia wspierającego amatorskich i półprofesjonalnych piwowarów. Każdy wiersz odpowiada jednej recepturze i zawiera ogólne parametry techniczne związane z procesem warzenia. Dane obejmują szeroki zakres ogólnych parametrów warzenia, takich jak styl piwa, zawartość alkoholu (ABV), poziom goryczki (IBU), kolor (SRM), gęstość początkowa (OG) i końcowa (FG), metoda warzenia (np. all grain, extract), objętości na różnych etapach produkcji, a także temperatury fermentacji. Dane mają postać numeryczną lub kategoriową i mogą służyć do analizy trendów, porównań stylów piwa, klasteryzacji receptur lub budowy modeli predykcyjnych opartych na parametrach fizykochemicznych trunku.

Określenie celu eksploracji i kryteriów sukcesu

Celem eksploracji jest klasyfikacja stylu piwa na podstawie jego właściwości fizykochemicznych, takich jak zawartość alkoholu (ABV), goryczka (IBU), gęstości (OG, FG), kolor (SRM) oraz metoda warzenia. Docelowo rozwiązywanym problemem jest klasyfikacja wieloklasowa, ponieważ styl piwa przyjmuje wiele możliwych wartości nominalnych. Dodatkowym celem jest zidentyfikowanie, które cechy mają największy wpływ na klasyfikację stylu piwa — będzie to realizowane m.in. przez analizę ważności cech (feature importance).

W przypadku tego problemu istotną metryką będzie **accuracy** (dokładność klasyfikacji), czyli stosunek poprawnie sklasyfikowanych próbek do ogólnej liczby próbek. Ze względu na potencjalną nierównowagę klas (niektóre style mogą występować znacznie częściej), dodatkowo zastosowane zostaną metryki:

Macro F1-score to średnia arytmetyczna wartości F1 obliczonych osobno dla każdej klasy. Traktuje wszystkie klasy z równą wagą, niezależnie od ich liczności. Jest to szczególnie przydatna metryka przy niezbalansowanych danych, ponieważ zapobiega faworyzowaniu dominujących klas.

Wzory:

- F1-score dla pojedynczej klasy:

$$F1 = 2 \cdot \frac{\text{precyzja} \cdot \text{czułość}}{\text{precyzja} + \text{czułość}}$$

- Precyzja (precision):

$$\text{precyzja} = \frac{TP}{TP + FP}$$

gdzie:

- TP (True Positive) – liczba przypadków poprawnie zaklasyfikowanych jako pozytywne (np. poprawnie rozpoznany styl piwa),
- FP (False Positive) – liczba przypadków błędnie zaklasyfikowanych jako pozytywne (np. piwo przypisane do danego stylu, chociaż nim nie jest).

- Czulość (recall):

$$\text{czułość} = \frac{TP}{TP + FN}$$

- Macro F1-score:

$$\text{macro F1-score} = \frac{1}{N} \sum_{i=1}^N F1_i$$

Gdzie (N) to liczba klas.

Confusion matrix

Macierz pomyłek (confusion matrix) pozwala przeanalizować, które style piwa są najczęściej mylone między sobą.

Sukces zostanie osiągnięty, jeżeli:

- model osiągnie **accuracy** powyżej 60%,
- model osiągnie **macro F1-score** powyżej 65%.

Przy wieloklasowym problemie klasyfikacyjnym i nieidealnie zbalansowanych danych będzie to oznaczać skuteczną eksplorację stylów piwa na podstawie parametrów technicznych.ch.

Charakterystyka zbioru danych

- **Pochodzenie:** Dane zostały zebrane z platformy Brewer's Friend i udostępnione na Kaggle przez użytkownika jtrofe.
- **Format:** .csv
- **Liczba przykładów:** 73 861 receptur piwa
- **Liczba atrybutów:** 23 kolumny opisujące właściwości każdej receptury
- **Struktura:** Zbiór składa się z dwóch plików:
 - **recipeData.csv** – główny zbiór zawierający informacje o recepturach piwa
 - **styleData.csv** – uzupełniający zbiór zawierający opisy stylów piwa

Opis atrybutów zbioru danych

Nazwa atrybutu	Typ	Znaczenie
BeerID	Numeryczny	ID przepisu
Name	Nominalny	Nazwa przepisu na piwo
URL	Nominalny	Ścieżka do przepisu na stronie https://www.brewersfriend.com
Style	Nominalny	Styl piwa
StyleID	Numeryczny	ID stylu
Size(L)	Numeryczny	Ilość piwa pozyskanego z przepisu w litrach
OG	Numeryczny	Gęstość brzezki przed fermentacją
FG	Numeryczny	Gęstość brzezki po fermentacji
ABV	Numeryczny	Zawartość alkoholu w %
IBU	Numeryczny	Miara stopnia goryczy wg. International Bitterness Units
Color	Numeryczny	Kolor określony metodą Standard Reference Method
BoilSize	Numeryczny	Ilość brzezki na początku gotowania
BoilTime	Numeryczny	Czas gotowania brzezki w minutach
BoilGravity	Numeryczny	Gęstość brzezki przed gotowaniem
Efficiency	Numeryczny	Wydajność zacierania piwa w %
MashThickness	Numeryczny	Ilość wody na funt ziaren
SugarScale	Nominalny	Określa zagęszczenie rozpuszczonych ciał stałych w brzezce
BrewMethod	Nominalny	Technika warzenia
PitchRate	Numeryczny	Ilość drożdży dodawanych do fermentora na jednostkę gęstości
PrimaryTemp	Numeryczny	Temperatura w etapie fermentacji

Nazwa atrybutu	Typ	Znaczenie
Priming Method	Nominalny	Typ cukru / sposobu dodania cukru do pobudzenia drożdży (Brak opisu na stronie Kaggle)
PrimingAmount	Nominalny	Ilość cukru używanego do pobudzenia drożdży
UserId	Numeryczny	ID autora przepisu

Wyniki eksploracyjnej analizy danych

W analizie danych pominęliśmy atrybuty: BeerID, Name, URL, UserId, SugarScale - głównie przez ich małe znaczenie dla eksploracyjnej analizy danych

Rozkłady wartości atrybutów

Już po wstępnej analizie zbioru danych zauważyliśmy, że spora część atrybutów numerycznych (między innymi: Size(L), OG, FG, ABV, IBU, BoilSize...) ma rozkład, w którym możemy zaobserwować dużą koncentrację próbek w relatywnie małym przedziale. Równocześnie, zaobserwowaliśmy obecność wartości znacznie odbiegających od innych (outlier'ów) - z tych powodów, do naszej analizy rozkładu wartości atrybutów oprócz histogramów, załączyliśmy także dodatkowe informacje statystyczne, takie jak średnia, odchylenie standardowe, wartości minimalne i maksymalne oraz liczba próbek dla tych wartości, natomiast przede wszystkim zdecydowaliśmy się na uwzględnienie kwantyli rozkładu (Q1 - 25%, Q2 - 50%, Q3 - 75%) oraz liczby próbek dla wartości powyżej Q3. Posiadając takie informacje, byliśmy w stanie przygotować histogramy dla rozkładów w zakresie IQR (Interquartile Range - rozstęp międzykwartyłowego) zakładając, że dana wartość jest outlierem, jeśli:

- jest mniejsza niż $Q1 - 1.5 * IQR$, lub
- jest większa niż $Q3 + 1.5 * IQR$

Dzięki temu, jesteśmy w stanie lepiej zrozumieć rozkład wartości atrybutów i ich potencjalny wpływ na dalsze analizy (oczywiście, nie wszystkie atrybuty wykazały potrzeby usuwania outlier'ów, natomiast metodę zastosowaliśmy dla każdej wizualizacji).

```
generate_histograms_for_dataset(recipe_data)
```

Analiza rozkładu dla atrybutu: StyleID




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	10.00	25743
Q2 (50%)	35.00	37135
Q3 (75%)	111.00	55863
> Q3 (75%)	-	17998





Tabela 2: Statystyki

	Wartość
Średnia	60.18
Odchylenie std.	56.81
Liczba próbek min. (=1)	137
Liczba próbek max. (=176)	67



Analiza rozkładu dla atrybutu: Size(L)




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	18.93	21685
Q2 (50%)	20.82	44014
Q3 (75%)	23.66	55449
> Q3 (75%)	-	18412





Tabela 2: Statystyki

	Wartość
Średnia	43.93
Odchylenie std.	180.37
Liczba próbek min. (=1.0)	6
Liczba próbek max. (=9200.0)	1



Analiza rozkładu dla atrybutu: OG




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	1.05	20897
Q2 (50%)	1.06	38255
Q3 (75%)	1.07	56378
> Q3 (75%)	-	17483




Tabela 2: Statystyki

	Wartość
Średnia	1.41
Odchylenie std.	2.20
Liczba próbek min. (=1.0)	35
Liczba próbek max. (=34.0345)	1

Analiza rozkładu dla atrybutu: FG




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	1.01	23377
Q2 (50%)	1.01	37969
Q3 (75%)	1.02	58413
> Q3 (75%)	-	15448




Tabela 2: Statystyki

	Wartość
Średnia	1.08
Odchylenie std.	0.43
Liczba próbek min. (=0.003)	1
Liczba próbek max. (=23.4246)	1

Analiza rozkładu dla atrybutu: ABV




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	5.08	18710
Q2 (50%)	5.79	37012
Q3 (75%)	6.83	55471
> Q3 (75%)	-	18390





Tabela 2: Statystyki

	Wartość
Średnia	6.14
Odchylenie std.	1.88
Liczba próbek min. (=0.0)	27
Liczba próbek max. (=54.72)	1



Analiza rozkładu dla atrybutu: IBU




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	23.37	18483
Q2 (50%)	35.77	36935
Q3 (75%)	56.38	55398
> Q3 (75%)	-	18463





Tabela 2: Statystyki

	Wartość
Średnia	44.28
Odchylenie std.	42.95
Liczba próbek min. (=0.0)	4159
Liczba próbek max. (=3409.3)	1



Analiza rozkładu dla atrybutu: Color




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	5.17	18499
Q2 (50%)	8.44	36973
Q3 (75%)	16.79	55409
> Q3 (75%)	-	18452




Tabela 2: Statystyki

	Wartość
Średnia	13.40
Odchylenie std.	11.94
Liczba próbek min. (=0.0)	101
Liczba próbek max. (=186.0)	1

Analiza rozkładu dla atrybutu: BoilSize




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	20.82	18814
Q2 (50%)	27.44	37080
Q3 (75%)	30.00	56268
> Q3 (75%)	-	17593




Tabela 2: Statystyki

	Wartość
Średnia	49.72
Odchylenie std.	193.25
Liczba próbek min. (=1.0)	6
Liczba próbek max. (=9700.0)	1

Analiza rozkładu dla atrybutu: BoilTime




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	60.00	57621
Q2 (50%)	60.00	57621
Q3 (75%)	60.00	57621
> Q3 (75%)	-	16240




Tabela 2: Statystyki

	Wartość
Średnia	65.07
Odchylenie std.	15.02
Liczba próbek min. (=0)	283
Liczba próbek max. (=240)	22

Analiza rozkładu dla atrybutu: BoilGravity




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	1.04	19095
Q2 (50%)	1.05	35662
Q3 (75%)	1.06	53861
> Q3 (75%)	-	17010




Tabela 2: Statystyki

	Wartość
Średnia	1.35
Odchylenie std.	1.93
Liczba próbek min. (=0.0)	5
Liczba próbek max. (=52.6)	1

Analiza rozkładu dla atrybutu: Efficiency




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	65.00	21536
Q2 (50%)	70.00	45856
Q3 (75%)	75.00	64341
> Q3 (75%)	-	9520




Tabela 2: Statystyki

	Wartość
Średnia	66.35
Odchylenie std.	14.09
Liczba próbek min. (=0.0)	101
Liczba próbek max. (=100.0)	187

Analiza rozkładu dla atrybutu: MashThickness




Tabela 1: Kwantyle

	Wartość kwantyli	Liczba próbek
Q1 (25%)	1.50	25509
Q2 (50%)	1.50	25509
Q3 (75%)	3.00	39882
> Q3 (75%)	-	4115






Tabela 2: Statystyki


	Wartość
Średnia	2.13
Odchylenie std.	1.68
Liczba próbek min. (=0.0)	8
Liczba próbek max. (=100.0)	1

Analiza rozkładu dla atrybutu: PitchRate





	Wartość kwantyli	Liczba próbek
Q1 (25%)	0.35	9528
Q2 (50%)	0.75	23999
Q3 (75%)	1.00	29193
> Q3 (75%)	-	5416

	Wartość
Średnia	0.75
Odchylenie std.	0.39
Liczba próbek min. (=0.0)	51
Liczba próbek max. (=2.0)	640




Analiza rozkładu dla atrybutu: PrimaryTemp



	Wartość kwantyli	Liczba próbek
Q1 (25%)	18.00	13443
Q2 (50%)	20.00	38444
Q3 (75%)	20.00	38444
> Q3 (75%)	-	12755

	Wartość
Średnia	19.18
Odchylenie std.	4.22
Liczba próbek min. (=17.78)	44
Liczba próbek max. (=114.0)	1



Wnioski z analizy rozkładów atrybutów numerycznych

1. Zmienne z dużą rozpiętością i obecnością outlierów

- `Size(L)` i `BoilSize` charakteryzują się bardzo szerokim zakresem wartości (od 1 do 9200 i 9700 litrów), co wskazuje na obecność ekstremalnych, bardzo dużych partii piwa w danych. Większość próbek jednak mieści się w stosunkowo wąskim przedziale (około 11.8–30.7 l dla `Size(L)` i 7.05–43.77 l dla `BoilSize`), po odrzuceniu wartości odstających.
- Wysokie odchylenia standardowe (180.37 dla `Size(L)` i 193.25 dla `BoilSize`) potwierdzają silną heterogeniczność w wielkości warzeń.
- `OG` i `FG`, mimo że ich zakresy nominalne są niewielkie (około 1.0–1.1 po odrzuceniu outlierów), w oryginalnym zestawie pojawiły się skrajne wartości (np. `OG` do 34, a `FG` do ponad 23), które należy traktować jako błędy pomiarowe lub dane nieprawidłowe.
- `ABV` ma zakres od 0 do ponad 54%, gdzie typowe wartości dla piwa są znacznie niższe (2.46–9.46% bez outlierów). Wskazuje to na obecność wartości odstających, które mogą być wynikiem błędów pomiarowych lub nietypowych produktów.
- `IBU` wykazuje bardzo duży zakres (0–3409), gdzie po odrzuceniu outlierów mieści się w zakresie do około 106. Prawdopodobnie te ekstremalne wartości wynikają z błędów lub nietypowych, eksperymentalnych receptur.
- `Color` ma szeroki zakres 0–186, jednak po wycięciu wartości odstających rozkład jest bardziej spójny i mieści się w typowych zakresach barwy piwa.

2. Zmienne o stosunkowo wąskich rozkładach


- `BoilTime` jest wyjątkowo jednorodny: mediana, kwartyle oraz większość próbek wynoszą dokładnie 60 minut, co wskazuje na standardową, powtarzalną długość gotowania brzezki.
- `Efficiency` ma umiarkowany rozkład skoncentrowany w przedziale 50–90%, co jest zgodne z typowymi wartościami wydajności procesu warzenia.
- `MashThickness` oraz `PitchRate` wykazują rozkłady z umiarkowanymi rozpiętościami, choć obecne są również wartości odstające (np. `MashThickness` do 100, co jest nietypowe).
- `PrimaryTemp` ma przeciętną wartość około 19°C i typowy zakres między 15 a 23°C po usunięciu outlierów, co jest zgodne z praktykami piwowarskimi.


3. Ogólne obserwacje

- W większości atrybutów można zauważyć obecność wartości odstających, które mogą wynikać z błędów pomiarowych, wpisów testowych lub wyjątkowych eksperymentów. W przypadku analiz predykcyjnych lub modelowania wskazane jest rozważenie ich usunięcia lub odpowiedniej transformacji danych.

- Rozkłady wielu zmiennych są asymetryczne z ogonami po stronie wartości wysokich, co sugeruje, że typowe piwa mają raczej umiarkowane parametry, a wartości bardzo duże lub bardzo niskie są rzadkością.
- Wartość odchylenia standardowego dla niektórych atrybutów jest znacznie wyższa od średniej, co dodatkowo potwierdza dużą zmienność i rozproszenie danych.

```
generate_spearman_matrix(recipe_data)
```





Wnioski z analizy korelacji

Na podstawie macierzy korelacji Spearmana, możemy zauważyć, że tylko część atrybutów jest ze sobą silnie skorelowana dodatnio, w macierzy najniższą wartością korelacji jest **-0.31**, co pokazuje, że w naszym zestawie danych nie występują silne korelacje ujemne.

Spośród najmocniejszych korelacji, możemy zauważyć, że:

- **OG** ↔ **ABV** : korelacja = 0.90

Bardzo silna dodatnia korelacja. **OG** oznacza początkową gęstość brzeczki, odzwierciedlającą stężenie cukrów możliwych do przekształcenia w alkohol w procesie fermentacji. Im wyższe **OG**, tym większy potencjał produkcji alkoholu, co przekłada się bezpośrednio na wyższy poziom **ABV**. Taka zależność jest zgodna z podstawowymi zasadami piwowarstwa.

- **Size(L)** ↔ **BoilSize** : korelacja = 0.79

Silna korelacja między całkowitą objętością warzonego piwa a objętością brzeczki gotowanej. Wyższy wolumen końcowego produktu wymaga proporcjonalnie większej objętości brzeczki do gotowania, co tłumaczy wysoką zgodność między tymi zmiennymi.

- **OG** ↔ **FG** : korelacja = 0.75

Również silna korelacja. Piwa o wyższej początkowej gęstości OG mają tendencję do zachowania wyższego poziomu cukrów resztkowych po fermentacji, co skutkuje wyższą końcową gęstością FG. Taka relacja odzwierciedla częściową efektywność procesu fermentacji.

- $OG \rightarrow BoilGravity$: korelacja = 0.69

Umiarkowanie silna dodatnia korelacja. BoilGravity to gęstość brzezki mierzona podczas gotowania. Jako że OG jest ostatecznym wynikiem rozcieńczania lub zagęszczania brzezki po gotowaniu, wartości te są ze sobą logicznie powiązane.

- $ABV \rightarrow BoilGravity$: korelacja = 0.60

Średnio silna korelacja. Wysoka gęstość brzezki podczas gotowania sugeruje większą koncentrację cukrów, co przekłada się na wyższy potencjał alkoholowy (ABV). Zależność ta nie jest jednak tak silna jak w przypadku OG, ponieważ BoilGravity nie uwzględnia późniejszego rozcieńczania lub innych etapów produkcji.

- $FG \rightarrow BoilGravity$: korelacja = 0.54

Umiarkowana korelacja. Brzezki o wyższej gęstości podczas gotowania mogą prowadzić do piw o wyższym poziomie cukrów resztkowych, co skutkuje wyższym FG.

- $FG \rightarrow ABV$: korelacja = 0.49

Relatywnie słaba dodatnia korelacja. Chociaż ABV w prostym modelu można wyliczyć jako różnicę pomiędzy OG a FG, to sama końcowa gęstość FG nie wystarcza do przewidywania zawartości alkoholu – istotny jest również punkt startowy fermentacji (OG).

Atrybut StyleID wykazuje bardzo niskie korelacje z większością cech, co sugeruje, że jego trafne przewidywanie na podstawie pojedynczych parametrów będzie trudne i może wymagać bardziej złożonych, nieliniowych modeli uwzględniających kombinacje wielu cech jednocześnie.

Uwagi na temat jakości danych

Dane brakujące

W naszym zestawie danych brakujące wartości w kolumnach zostały oznaczone wartościami N/A. Braki w kolumnach wyglądają następująco:

- Style (oraz wartości StyleID równe 111 - oznaczające N/A) - brakujących wartości: 596
- BoilGravity - brakujących wartości: 2990
- MashThickness - brakujących wartości: 29864
- PitchRate - brakujących wartości: 39252

- `PrimaryTemp` - brakujących wartości: 22662
- `PrimingMethod` - brakujących wartości: 67101
- `PrimingAmount` - brakujących wartości: 69087

Przypomnienie: w zestawie danych znajduje się 73861 wierszy

Dane niezrozumiałe i niespójne


Dane w ogólności są dość intuicyjne i zrozumiałe, a zestaw na stronie Kaggle zawiera opisy dla większości atrybutów. Niemniej jednak, część danych jest zarówno niezrozumiała, jak i niespójna, co może utrudniać analizę:

- Brakuje sprecyzowanych jednostek w kolumnach takich jak `BoilSize`, `BoilTime`, `PrimaryTemp`.
- `PrimingAmount` oraz `PrimingMethod` zawiera dane wprowadzane ręcznie przez użytkowników, często w różnych formatach, jednostkach, a nawet językach. Na przykład:
 - Dla `PrimingAmount`: 1.25 Cups, 6g/l, 5 5 g sukker/l, ~2/3 cup, 3.5 Oz (1/2 Cup)
 - Dla `PrimingMethod`: forced carbonation, Corn Sugar, Sukkerlake, Table sugar. 18L, bottle conditioning
- `PrimingMethod` nie posiada żadnego opisu ani na stronie Kaggle, ani w metadanych zbioru.
- `SugarScale` zawiera tylko dwie unikatowe wartości których znaczenie nie jest wyjaśnione.
- Część kolumn zawiera wartości odstające lub niekonsekwentne z kontekstem (np. liczby zmieszane z tekstem).


Dla celów dalszej analizy posłużymy się materiałami posiłkowymi ze strony www.brewersfriend.com, z której pochodzą dane, jednak w samym zbiorze wiele szczegółów zostało pominiętych lub wprowadzonych w sposób niespójny.

Punkty oddalone

```
generate_boxplots_for_dataset(recipe_data)
```





Statystyka	Wartość
Przedział wartości występujących najczęściej	5.73 - 10.46
Mediana	35.00
Liczba punktów oddalonych	0
Procent punktów oddalonych w zestawie	0.00%




Statystyka	Wartość
Przedział wartości występujących najczęściej	20.62 - 20.84
Mediana	20.82
Liczba punktów oddalonych	19366
Procent punktów oddalonych w zestawie	26.22%

Analiza atrybutu: OG




Statystyka	Wartość
Przedział wartości występujących najczęściej	1.05 - 1.05
Mediana	1.06
Liczba punktów oddalonych	4871
Procent punktów oddalonych w zestawie	6.59%

Analiza atrybutu: FG




Statystyka	Wartość
Przedział wartości występujących najczęściej	1.01 - 1.01
Mediana	1.01
Liczba punktów oddalonych	4211
Procent punktów oddalonych w zestawie	5.70%

Analiza atrybutu: ABV




Statystyka	Wartość
Przedział wartości występujących najczęściej	5.09 - 5.17
Mediana	5.79
Liczba punktów oddalonych	3765
Procent punktów oddalonych w zestawie	5.10%

Analiza atrybutu: IBU




Statystyka	Wartość
Przedział wartości występujących najczęściej	0.00 - 1.57
Mediana	35.77
Liczba punktów oddalonych	3565
Procent punktów oddalonych w zestawie	4.83%

Analiza atrybutu: Color




Statystyka	Wartość
Przedział wartości występujących najczęściej	3.32 - 3.88
Mediana	8.44
Liczba punktów oddalonych	7353
Procent punktów oddalonych w zestawie	9.96%

Analiza atrybutu: BoilSize




Statystyka	Wartość
Przedział wartości występujących najczęściej	28.13 - 28.57
Mediana	27.44
Liczba punktów oddalonych	12955
Procent punktów oddalonych w zestawie	17.54%

Analiza atrybutu: BoilTime




Statystyka	Wartość
Przedział wartości występujących najczęściej	53.33 - 66.67
Mediana	60.00
Liczba punktów oddalonych	18557
Procent punktów oddalonych w zestawie	25.12%

Analiza atrybutu: BoilGravity




Statystyka	Wartość
Przedział wartości występujących najczęściej	1.04 - 1.04
Mediana	1.05
Liczba punktów oddalonych	7140
Procent punktów oddalonych w zestawie	10.07%

Analiza atrybutu: Efficiency




Statystyka	Wartość
Przedział wartości występujących najczęściej	70.00 - 70.48
Mediana	70.00
Liczba punktów oddalonych	10151
Procent punktów oddalonych w zestawie	13.74%

Analiza atrybutu: MashThickness




Statystyka	Wartość
Przedział wartości występujących najczęściej	1.44 - 1.53
Mediana	1.50
Liczba punktów oddalonych	425
Procent punktów oddalonych w zestawie	0.97%

Analiza atrybutu: PitchRate



Statystyka	Wartość
Przedział wartości występujących najczęściej	0.31 - 0.35
Mediana	0.75
Liczba punktów oddalonych	640
Procent punktów oddalonych w zestawie	1.85%

Analiza atrybutu: PrimaryTemp



Statystyka	Wartość
Przedział wartości występujących najczęściej	19.90 - 20.01
Mediana	20.00
Liczba punktów oddalonych	6324
Procent punktów oddalonych w zestawie	12.35%

Punkty oddalone – wnioski

Analiza punktów oddalonych dla cech związanych z procesem warzenia piwa ujawnia zróżnicowany poziom rozrzutu wartości:

- Największy odsetek punktów oddalonych występuje w `Size(L)` (26.22%) i `BoilTime` (25.12%). Świadczy to o dużej różnorodności w objętości produkcji i czasie gotowania brzeczki, co może być efektem zarówno różnic technologicznych (np. piwowarstwo domowe vs. przemysłowe), jak i błędów wprowadzania danych.
- Istotne odchylenia widoczne są również w `BoilSize`, `Efficiency` i `PrimaryTemp`, gdzie punktów oddalonych jest od 10% do 17%. Może to wskazywać na różne techniki i sprzęt używany przez piwowarów, a także możliwe przypadki niestandardowych praktyk fermentacyjnych.
- Atrybuty związane z parametrami piwa jak `OG`, `FG`, `ABV`, `IBU` i `Color` mają umiarkowaną liczbę punktów oddalonych (4.8%–10%). Odzwierciedla to naturalne różnice w recepturach, surowcach i stylach piwa, co jest typowe w branży rzemieślniczej.
- Najmniejszy udział outlierów zaobserwowano w `MashThickness` (0.97%) i `PitchRate` (1.85%), co może sugerować, że parametry te są bardziej standaryzowane i kontrolowane przez piwowarów.

Obecność punktów oddalonych jest zróżnicowana w zależności od atrybutu, co wskazuje na szerokie spektrum podejść do warzenia piwa. Dla atrybutów technologicznych (np. `Size(L)`, `BoilTime`) duży rozrzut może utrudniać analizę statystyczną – warto w tych przypadkach stosować metody odporne na wartości odstające. Z kolei zmienne związane z cechami sensorycznymi i składem piwa pokazują rozsądną zmienność, typową dla różnorodnych stylów i receptur.

Zaleca się dalszą analizę outlierów – zwłaszcza w kontekście możliwych błędów w danych lub identyfikacji wyjątkowych przypadków, które mogą być ciekawe z punktu widzenia innowacji piwowarskich.

Podsumowanie

Celem eksploracji było lepsze zrozumienie struktury i jakości danych zebranych z platformy `Brewer's Friend`, zawierających receptury piwa wraz z ich parametrami technologicznymi i fizykochemicznymi. Przeprowadzona analiza pozwoliła ocenić zarówno zawartość informacyjną zbioru, jak i jego ograniczenia.

Większość zmiennych liczbowych (takich jak `OG`, `FG`, `ABV`, `IBU`, `Color`, `Size(L)`, `BoilSize`) prezentuje realistyczne wartości mieszczące się w znanych zakresach typowych dla warzenia piwa. Analiza rozkładów ujawniła jednak obecność licznych wartości odstających, w niektórych przypadkach ekstremalnych, które mogą wynikać z błędów wprowadzania danych, eksperymentalnych receptur lub różnic w skali produkcji.

Jednocześnie zauważyliśmy, że zmienna `StyleID` – kluczowa dla dalszych analiz – wykazuje bardzo słabe korelacje z pozostałymi cechami. Sugeruje to, że styl piwa nie zależy od

pojedynczej zmiennej, ale może być wynikiem złożonej kombinacji wielu cech, co powinno być brane pod uwagę w kolejnych etapach eksploracji.

W zbiorze występuje istotna liczba brakujących wartości — dotyczy to zwłaszcza kolumn takich jak `PitchRate`, `PrimaryTemp`, `MashThickness`, `BoilGravity`, a także `PrimingMethod` i `PrimingAmount`, które zawierają nawet kilkadziesiąt tysięcy braków. Ich obecność wymusza rozważenie uzupełnienia danych lub usunięcia tych atrybutów z dalszej analizy.

Dodatkowo dane są częściowo niespójne i niejednoznaczne. Część kolumn nie posiada określonych jednostek, a inne zawierają dane wprowadzane ręcznie przez użytkowników (`PrimingAmount`, `PrimingMethod`), co prowadzi do obecności wielu formatów, języków i jednostek w jednej kolumnie. Tego typu niejednorodność może znacząco utrudniać analizę.

Podsumowując, dane dostarczają wartościowych i różnorodnych informacji, jednak ich efektywne wykorzystanie wymaga ostrożności – zwłaszcza w zakresie oczyszczania, identyfikacji i obsługi wartości odstających, a także radzenia sobie z brakami i niespójnościami. Pomimo tych wyzwań, postawiony cel eksploracji danych pozostaje realistyczny i możliwy do osiągnięcia.

Jeśli realizacja eksploracji względem `StyleID` okaże się niewystarczająco efektywna, rozważymy skupienie się na innym, bardziej stabilnym atrybucie.